

MVP DE ENGENHARIA DE DADOS

Pipeline Analítico do E-commerce Olist

Aluno: Ygor Ribeiro

Plataforma: Databricks Free Edition

Arquitetura: Medalhão (Bronze, Silver e Gold)

Dataset: Brazilian E-Commerce Public Dataset by Olist

Documento de apoio para entrega do MVP

1. Contexto de Negócios e Perguntas

1.1 Objetivo

O objetivo do projeto é implementar um pipeline de dados ponta a ponta em ambiente de nuvem para organizar, tratar e disponibilizar dados de e-commerce da Olist para análise. A solução foi estruturada na Arquitetura Medalhão, separando dados brutos, dados tratados e dados modelados para consumo analítico. O foco de negócio é compreender faturamento, desempenho logístico, satisfação dos clientes, meios de pagamento e fluxos de entrega entre estados brasileiros.

1.2 Perguntas de negócio

1. Quais categorias de produtos apresentam maior receita bruta e qual é o ticket médio por item?
2. Qual é o tempo médio de entrega e a taxa de atraso por estado de destino?
3. Como o atraso na entrega se relaciona com a nota de satisfação atribuída pelos clientes?
4. Como se distribuem o volume financeiro, o número de transações e o parcelamento entre os meios de pagamento?
5. Como frete, prazo de entrega e taxa de atraso variam entre fluxos intraestaduais e interestaduais?

1.3 Fonte, contexto e licença

Foi utilizado o conjunto Brazilian E-Commerce Public Dataset by Olist, disponibilizado no Kaggle (<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>). O conjunto reúne informações de pedidos, itens, pagamentos, avaliações, produtos, clientes, vendedores, geolocalização e tradução de categorias. A documentação da fonte e sua licença devem ser consultadas na página oficial do dataset antes da submissão final, mantendo a devida atribuição à Olist e ao Kaggle.

1.4 Estrutura dos arquivos de origem


Arquivo	Conteúdo principal
olist_orders_dataset.csv	Pedidos, status e datas do ciclo do pedido e da entrega.
olist_order_items_dataset.csv	Itens dos pedidos, produto, vendedor, preço e frete.
olist_order_payments_dataset.csv	Meios de pagamento, parcelas e valores pagos.
olist_order_reviews_dataset.csv	Avaliações e notas atribuídas pelos clientes.
olist_products_dataset.csv	Produtos, categorias, peso e dimensões.
olist_customers_dataset.csv	Clientes e localização de destino.
olist_sellers_dataset.csv	Vendedores e localização de origem.
olist_geolocation_dataset.csv	Coordenadas geográficas (lat/long) associadas a CEPs, usada para enriquecer localização de clientes e vendedores.
product_category_name_translation.csv	Tradução das categorias de produtos.

2. Carga dos Dados

A coleta foi realizada por meio do upload dos 9 arquivos CSV do dataset para um Volume gerenciado do Unity Catalog no Databricks Free Edition (workspace.default.raw_files). Essa etapa disponibilizou a fonte bruta em ambiente de nuvem para leitura pelos notebooks PySpark/SQL e garantiu a separação entre os arquivos originais e as tabelas Delta geradas ao longo do pipeline.

2.1 Referência aos scripts

- ingestao_tratamento_olist.ipynb: ingestão, transformações Bronze/Silver/Gold e consultas analíticas.
- unity_catalog.ipynb: criação e documentação dos objetos no Unity Catalog.



3. Modelagem e Catálogo de Dados

A camada Gold foi organizada para consumo analítico, separando medidas de negócio em tabelas fato e atributos descritivos em tabelas dimensão. O modelo reduz a complexidade das consultas e permite responder às perguntas de negócio diretamente sobre dados tratados.

3.1 Estrutura da camada Gold

Tipo	Tabela	Finalidade
Fato	fato_itens_pedidos	Métricas por item de pedido: preço, frete, valor total, entrega e avaliação.
Fato	fato_pagamentos	Transações financeiras por pedido e modalidade de pagamento.
Dimensão	dim_cliente	Atributos e localização do cliente.
Dimensão	dim_vendedor	Atributos e localização do vendedor.
Dimensão	dim_produto	Produto, categoria e atributos físicos.
Dimensão	dim_tempo	Atributos de calendário derivados da data de compra.

3.2 Catálogo de dados — campos principais

Os metadados foram documentados no Unity Catalog por meio de comentários em tabelas e colunas. A tabela abaixo resume os campos analíticos centrais.

Tabela	Campo	Tipo	Descrição / origem
fato_itens_pedidos	order_id	STRING	Identificador do pedido; origem em orders.
fato_itens_pedidos	product_id	STRING	Produto do item; origem em order_items.
fato_itens_pedidos	seller_id	STRING	Vendedor do item; origem em order_items.
fato_itens_pedidos	customer_id	STRING	Cliente associado ao pedido; origem em orders.
fato_itens_pedidos	data_compra	DATE	Data da compra; derivada do timestamp do pedido.
fato_itens_pedidos	valor_item	DECIMAL	Preço do item.
fato_itens_pedidos	valor_frete	DECIMAL	Valor de frete atribuído ao item.
fato_itens_pedidos	dias_entrega_real	INT	Diferença entre compra e entrega, quando disponível.
fato_itens_pedidos	dias_entrega_estimada	INT	Diferença entre compra e data estimada.
fato_itens_pedidos	flag_atraso_entrega	INT	Indicador calculado de atraso.
fato_itens_pedidos	review_score	DOUBLE	Nota de avaliação, convertida de forma defensiva.
fato_pagamentos	payment_type	STRING	Modalidade de pagamento.
fato_pagamentos	payment_installments	INT	Quantidade de parcelas.

fato_pagamentos	valor_pagamento	DECIMAL	Valor liquidado na transação.
-----------------	-----------------	---------	-------------------------------

+

New

Home

Learn

Workspace

Recents

Catalog

Jobs & Pipelines

Compute

Discover

Marketplace

SQL

SQL Editor

Queries

Dashboards

Genie Agents

Alerts

Query History

SQL Warehouses

Data Engineering

Runs

Data Ingestion

Visual Data Prep

AU/ML

Catalog

Serverless Starter Warehouse Serverless 2XS

Catalog

Type to search

My organization

workspace

bronze

default

gold

Tables (6)

dim_cliente

dim_produto

dim_tempo

dim_vendedor

fato_itens_pedidos

fato_pagamentos

information_schema

silver

system

Shares received

samples

Catalog Explorer > workspace > gold >

fato_itens_pedidos

Open in a dashboard

Share

Create

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Tabela fato central granular por item de pedido. Reúne métricas financeiras, logísticas de entrega e nota de avaliação do cliente.

Filter columns...

AI generate

Column	Type	Popular...	Comment	Tags	Column masking	
order_id	string	...	Identificador único do pedido (origem: orders).			
order_item_id	int	...	Sequencial do item dentro do pedido (1, 2, 3...).			
product_id	string	...	Chave estrangeira para dim_produto.			
seller_id	string	...	Chave estrangeira para dim_vendedor.			
customer_id	string	...	Chave estrangeira para dim_cliente.			
data_compra	date	...	Data da realização da compra (chave para dim_tempo).			

order_status	string	----	Status operacional do pedido (ex: delivered, shipped, canceled).
valor_item	decimal...	.	Preço unitário do produto em reais. Domínio: valores decimais ≥ 0.00 .
valor_frete	decimal...	.	Custo de frete do item em reais. Domínio: valores decimais ≥ 0.00 .
valor_total_item	decimal...	----	Soma de valor_item + valor_frete em reais.
order_purchase_timestamp	timesta...	----	
order_delivered_customer...	timesta...	----	Add comment Add tags Add column mask >
order_estimated_delivery_d...	timesta...	----	
dias_entrega_real	int	.	Tempo decorrido entre a compra e a entrega real ao cliente em dias.
dias_entrega_estimada	int	.	Prazo previsto informado no momento da compra em dias.
flag_atraso_entrega	int	.	Indicador binário de atraso: 1 se entrega real > estimada, 0 se entregue no prazo.

review_score	double	.	Nota média de avaliação do pedido. Domínio: 1.0 a 5.0.
--------------	--------	---	--

About this table

Owner ygorribeiro@id.uff.br 
Type  Managed 
Data source  Delta
Popularity .|||

4. Pipeline de Dados

O pipeline foi implementado em notebooks no Databricks e organizado em três camadas persistidas: Bronze, Silver e Gold. As tabelas foram gravadas como Delta, permitindo que cada etapa seja reexecutada de forma reproduzível a partir da fonte bruta.

4.1 Bronze — dados brutos


Os arquivos CSV do Volume foram lidos e persistidos sem alteração de significado de negócio, preservando a rastreabilidade da fonte original.

4.2 Silver — limpeza e padronização

Nesta camada foram aplicadas deduplicação, conversões de tipos, padronização de campos e tratamento de valores ausentes.

4.3 Gold — modelo para análise

A camada Gold consolida pedidos, itens, clientes, produtos, vendedores, avaliações e pagamentos em tabelas fato e dimensão, com métricas derivadas de prazo e atraso.



08:55 PM (31s) 26 SQL

```
%sql
SHOW TABLES IN workspace.gold;
```

> [See performance \(1\)](#) ✓ Checked for improvements

	database	tableName	isTemporary
1	gold	dim_cliente	false
2	gold	dim_produto	false
3	gold	dim_tempo	false
4	gold	dim_vendedor	false
5	gold	fato_itens_pedidos	false
6	gold	fato_pagamentos	false

5. Qualidade de Dados


A qualidade foi avaliada sob as dimensões de completude, consistência, unicidade e validade de tipos, aplicadas durante as transformações e antes das consultas analíticas.

5.1 Problema identificado e tratamento

Na tabela de avaliações, a coluna review_score continha valores incompatíveis com o tipo numérico, incluindo timestamps. Para evitar interrupção do pipeline, a agregação foi ajustada com TRY_CAST(review_score AS DOUBLE), convertendo valores inválidos em nulos e preservando a integridade da média.

5.2 Controles aplicados

- Deduplicação de registros conforme chaves de negócio em cada entidade.
- Conversão explícita de datas, métricas financeiras e campos numéricos relevantes.
- Tratamento defensivo de valores inválidos em review_score com TRY_CAST.
- Validação de valores nulos e de campos críticos antes da análise da camada Gold.



The screenshot shows a SQL query being executed in a workspace. The query calculates various metrics for items from the 'workspace.gold.fato_itens_pedidos' table. The results are displayed in a table with 7 columns: total_itens_gold, nulos_valor_item, nulos_valor_frete, nulos_data_compra, itens_com_atraso, and media_geral_review_score. The results show 11,265 items with zero null values for the first four metrics, 8,715 items with delays, and an average review score of 4.04.

```

%sql
SELECT
  COUNT(*) AS total_itens_gold,
  SUM(CASE WHEN valor_item IS NULL THEN 1 ELSE 0 END) AS nulos_valor_item,
  SUM(CASE WHEN valor_frete IS NULL THEN 1 ELSE 0 END) AS nulos_valor_frete,
  SUM(CASE WHEN data_compra IS NULL THEN 1 ELSE 0 END) AS nulos_data_compra,
  SUM(CASE WHEN flag_atraso_entrega = 1 THEN 1 ELSE 0 END) AS itens_com_atraso,
  ROUND(AVG(review_score), 2) AS media_geral_review_score
FROM workspace.gold.fato_itens_pedidos;

```

	total_itens_gold	nulos_valor_item	nulos_valor_frete	nulos_data_compra	itens_com_atraso	media_geral_review_score
1	112650	0	0	0	8715	4.04

6. Análise de Dados

As cinco perguntas de negócio foram respondidas com consultas SQL sobre a camada Gold. Para cada pergunta abaixo: insira o print do resultado da query e, logo em seguida, o texto de discussão interpretando os números.

Pergunta 1 — Receita por categoria

Objetivo: identificar as categorias com maior receita bruta e o ticket médio por item.

categoria_produto	total_itens_vendidos	receita_bruta_produtos	ticket_medio_item
health_beauty	9670	1258681.34	130.16
watches_gifts	5991	1205005.68	201.14
bed_bath_table	11115	1036988.68	93.30
sports_leisure	8641	988048.97	114.34
computers_accessories	7827	911954.32	116.51
furniture_decor	8334	729762.49	87.56
cool_stuff	3796	635290.85	167.36
housewares	6964	632248.66	90.79
auto	4235	592720.11	139.96
garden_tools	4347	485256.46	111.63

Discussão: A análise dos resultados revela que a categoria health_beauty lidera o faturamento da plataforma com R\$ 1.258.681,34 gerados a partir de 9.670 itens vendidos (ticket médio de R\$ 130,16), seguida de perto por watches_gifts, que acumulou R\$ 1.205.005,68. Observa-se uma importante distinção entre volume físico e valor financeiro: a categoria bed_bath_table foi a mais volumosa em unidades vendidas (11.115 itens), porém ocupa o terceiro lugar em receita total devido ao seu ticket médio menor (R\$ 93,30). Em contrapartida, watches_gifts alcançou a vice-liderança em faturamento com quase metade do volume de vendas (5.991 itens), impulsionada pelo maior ticket médio do ranking (R\$ 201,14). Isso indica que estratégias comerciais de e-commerce devem equilibrar categorias de alto giro e margem unitária moderada com nichos de alto valor agregado.

Pergunta 2 — Entregas e atraso por UF

Objetivo: medir prazo médio de entrega e taxa de atraso por estado de destino.

estado_destino	total_entregas	media_dias_entrega	media_dias_estimados	taxa_atraso_percentual
AL	427	24.4	33.2	24.12
MA	800	21.6	31.5	20.38
SE	375	21.4	31.4	16.27
PI	523	19.3	30.8	15.49
CE	1426	20.9	32.0	15.29
BA	3683	19.2	30.2	13.68
RJ	14143	15.1	27.1	12.97
PA	1054	23.7	38.0	12.43
TO	310	17.4	29.7	12.26
ES	2225	15.6	26.2	12.22
PB	586	20.5	33.6	11.26
RR	46	28.2	46.5	10.87
MS	811	15.5	26.7	10.85
RN	521	19.3	33.2	10.36
PE	1746	18.2	31.7	10.19
SC	4097	14.9	26.5	9.62
GO	2277	15.3	27.6	7.86
DF	2355	12.9	25.1	7.43

RS	6133	15.1	29.3	6.88
MT	1037	17.9	32.5	6.75
SP	46441	8.7	19.9	5.77
MG	12916	11.9	25.3	5.44
AP	81	28.2	46.6	4.94
PR	5649	11.9	25.4	4.78
AM	163	26.3	46.3	4.29
RO	273	19.7	39.7	4.03
AC	91	20.7	41.7	3.30

Discussão: Os indicadores revelam uma disparidade logística e geográfica substancial no comércio eletrônico brasileiro. Estados das regiões Norte e Nordeste concentram os maiores prazos médios de entrega e as taxas de atraso mais elevadas em relação à data estimada pelo marketplace: Alagoas lidera com taxa de atraso de 24,12% (prazo médio de 24,4 dias), seguida por Maranhão com 20,38% de atrasos (21,6 dias) e Sergipe com 16,27% (21,4 dias). Em contraste, o estado de São Paulo, polo econômico onde se concentra a maior base consumidora (46.441 pedidos entregues) e a maior parte dos centros de distribuição dos vendedores, apresenta uma taxa de atraso de apenas 5,77% e um prazo médio de 8,7 dias. O estado de Minas Gerais também apresentou alta eficiência logística, com 5,44% de atrasos e média de 13,0 dias. Essa assimetria reflete os desafios de infraestrutura e dependência de malha rodoviária de longa distância para entregas fora do eixo Sul-Sudeste, sugerindo a oportunidade de implantação de centros de consolidação e redistribuição regional.

Pergunta 3 — Satisfação vs. atraso

Objetivo: comparar a nota média de avaliação entre pedidos entregues no prazo e com atraso.

situacao_entrega	total_itens	nota_media_avaliacao	percentual_nota_1	percentual_nota_5
No Prazo	100375	4.21	8.35	60.56
Com Atraso	8462	2.55	46.87	22.17

Discussão: Os dados comprovam uma correlação negativa severa entre o descumprimento do prazo de entrega e a percepção de qualidade pelo cliente. Quando o pedido é entregue dentro da data estimada (100.900 itens avaliados), a nota média de satisfação atinge 4,21 estrelas (em escala de 1 a 5), com 60,56% dos consumidores concedendo a nota máxima 5 e apenas 8,35% atribuindo a nota mínima 1. Por outro lado, quando ocorre atraso logístico (7.376 itens), a nota média despenca para 2,55 estrelas, enquanto a incidência de avaliações com nota 1 salta exponencialmente para 46,87% — um aumento de mais de cinco vezes nas queixas severas. Esses resultados evidenciam que o cumprimento do prazo de entrega prometido é a variável operacional mais crítica para a retenção, recomendação de marca e satisfação geral do consumidor na plataforma.

Pergunta 4 — Meios de pagamento

Objetivo: entender a distribuição de faturamento, transações e parcelamento por modalidade de pagamento.

metodo_pagamento	total_transacoes	faturamento_total	ticket_medio_transacao	media_parcelas
credit_card	76795	12542084.19	163.32	3.5
boleto	19784	2869361.27	145.03	1.0
voucher	5775	379436.87	65.70	1.0
debit_card	1529	217989.79	142.57	1.0
not_defined	3	0.00	0.00	1.0

Discussão: O cartão de crédito consolida-se como a principal alavanca de liquidação financeira e faturamento do marketplace, respondendo por R\$ 12.542.084,19 transacionados em 76.795 operações — o que representa cerca de 78% do volume monetário total analisado. Essa modalidade também apresentou o maior ticket médio individual (R\$ 163,32) e um comportamento médio de parcelamento de 3,5 parcelas por transação, viabilizando compras de maior valor. O boleto bancário representa a segunda principal força de pagamento, somando R\$ 2.869.361,69 em 19.784 transações, sempre à vista (1 parcela) e com ticket médio de R\$ 145,03. Vouchers e cartões de débito desempenham papel complementar no ecossistema (R\$ 379 mil e R\$ 217 mil, respectivamente). A dependência do parcelamento via cartão reforça a importância de taxas atrativas de intermediação de crédito para sustentar o faturamento da plataforma.

Pergunta 5 — Fluxo intraestadual vs. interestadual

Objetivo: comparar frete, prazo e atraso entre entregas dentro do mesmo estado e entre estados diferentes.

tipo_fluxo_logistico	total_itens	frete_medio	media_dias_entrega	taxa_atraso_percentual
Interestadual (Estados Diferentes)	70328	23.63	15.0	9.00
Intraestadual (Mesmo Estado)	39861	13.45	7.9	5.98

Discussão: A comparação operacional evidencia que o comércio eletrônico estudado é predominantemente interestadual: 70.328 itens (cerca de 63,8% do total com localização mapeada) foram expedidos entre estados diferentes, enquanto 39.861 itens foram comercializados dentro da mesma unidade federativa. O frete interestadual apresentou um custo médio 75,7% superior ao intraestadual (R\$ 23,63 contra R\$ 13,45 por item), além de exigir praticamente o dobro do tempo de trânsito (15,0 dias contra 7,9 dias). Como consequência da maior complexidade na cadeia de transporte de longa distância, a taxa de atraso também foi 50,5% maior nas rotas interestaduais (9,00% versus 5,98%). Esses dados ratificam o

impacto financeiro e operacional que o frete exerce sobre o consumidor e indicam a relevância de incentivar o cadastro de vendedores regionais próximos aos grandes centros de demanda fora do Sudeste.

7. Autoavaliação

O objetivo central de construir um pipeline de dados em nuvem foi atingido: os dados foram carregados, organizados em camadas Bronze, Silver e Gold, documentados no Unity Catalog e utilizados em consultas analíticas. A principal dificuldade técnica foi lidar com inconsistências de tipo no campo de avaliação, resolvida por meio de conversão defensiva com TRY_CAST. Como evolução futura, recomenda-se automatizar a execução do pipeline com Jobs/Workflows, ampliar as regras de qualidade e disponibilizar os indicadores Gold em um dashboard de BI.

8. Repositório e Evidências

Código-fonte disponível no repositório público: <https://github.com/Ygor-RR/mvp-engenharia-dados-olist>

Checklist final de evidências: upload dos 9 CSVs no Volume; tabelas Bronze/Silver/Gold; catálogo e comentários; persistência das tabelas Gold; consultas das cinco perguntas com discussão; validações de qualidade.